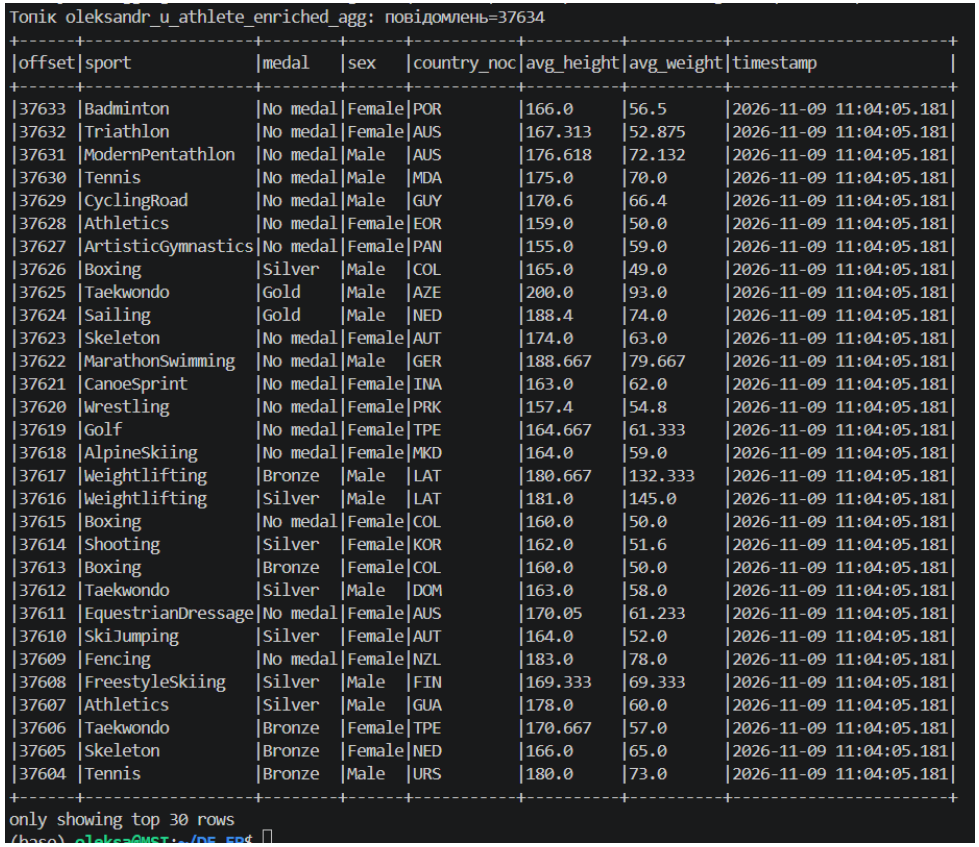
Частина 1. Streaming: MySQL + Kafka → Spark → Kafka + MySQL

Біо-дані атлетів читаються з MySQL olympic_dataset.athlete_bio, рядки з порожнім або нечисловим зростом/вагою відкидаються. Результати змагань переливаються з MySQL у топік `oleksandr_u_athlete_event_results`, стрим читає їх з Kafka, розкладає JSON на колонки, джойнить з біо за `athlete_id` і рахує середні зріст і вагу за sport / medal / sex / country_noc. Відсутня медаль (`nan`) іде окремою категорією `No medal`. Кожен мікробатч через `forEachBatch` пишеться в обидва sink-и. Код: `part1_streaming/`.

Вихідний Kafka-топік

Етап 6.a. Друк топіку `oleksandr_u_athlete_enriched_agg` скриптом `p1_03_read_output_topic.py`: кожне повідомлення — один агрегат із часовою міткою розрахунку.



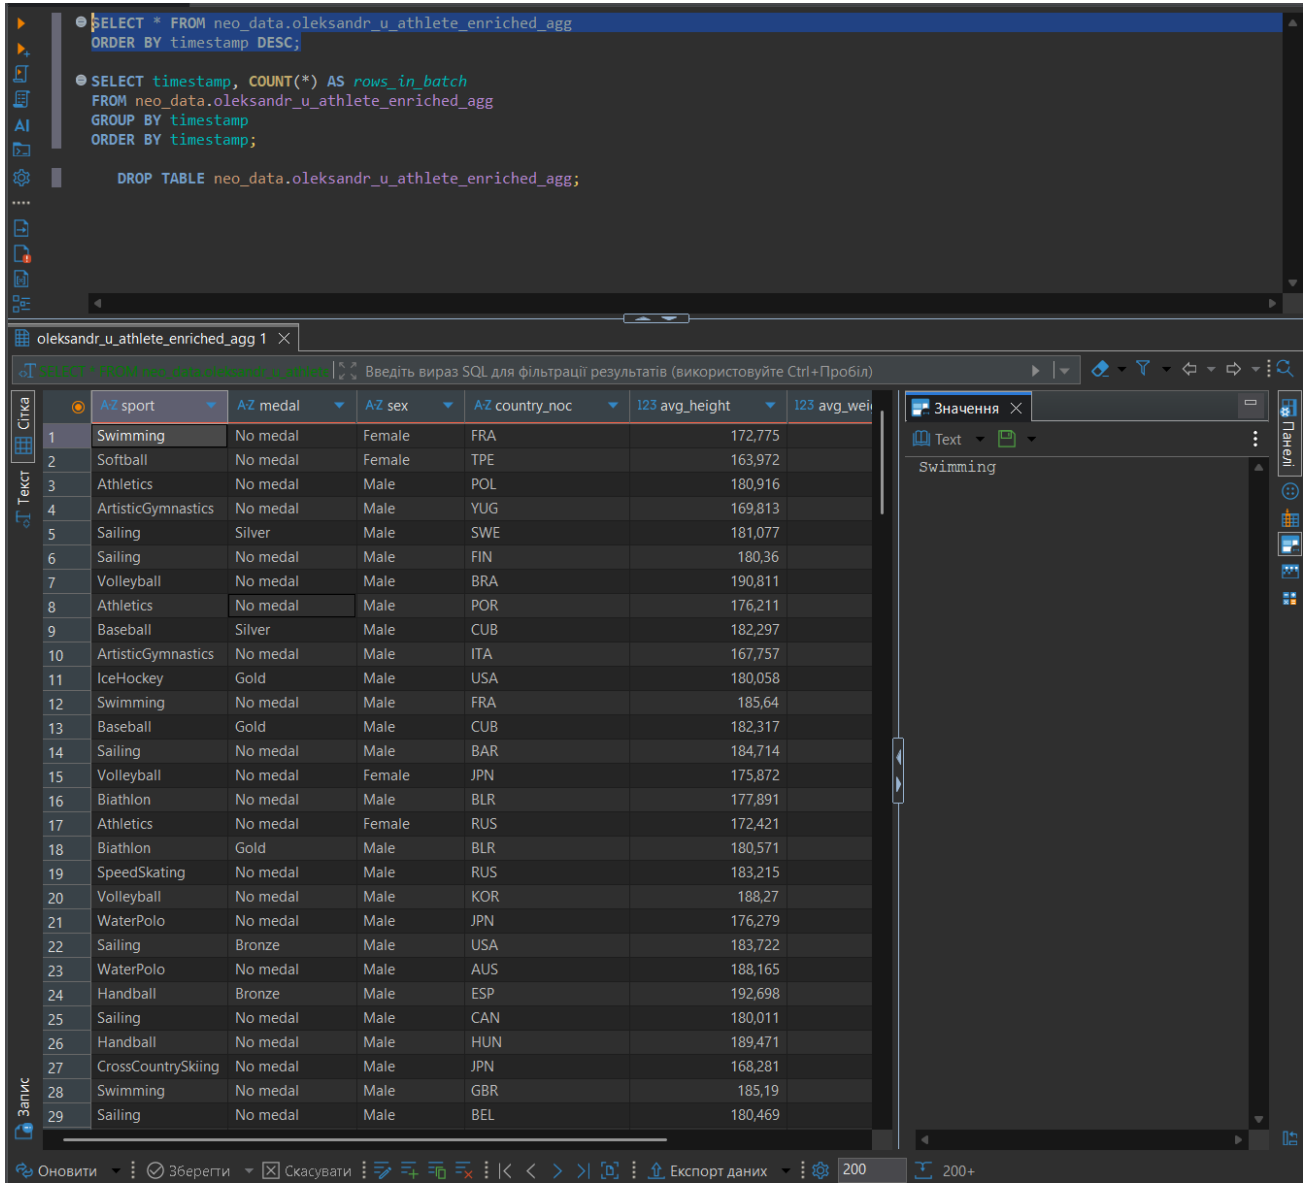
Топік oleksandr_u_athlete_enriched_agg: повідомлень=37634

offset	sport	medal	sex	country_noc	avg_height	avg_weight	timestamp
37633	Badminton	No medal	Female	POR	166.0	56.5	2026-11-09 11:04:05.181
37632	Triathlon	No medal	Female	AUS	167.313	52.875	2026-11-09 11:04:05.181
37631	ModernPentathlon	No medal	Male	AUS	176.618	72.132	2026-11-09 11:04:05.181
37630	Tennis	No medal	Male	MDA	175.0	70.0	2026-11-09 11:04:05.181
37629	CyclingRoad	No medal	Male	GUY	170.6	66.4	2026-11-09 11:04:05.181
37628	Athletics	No medal	Female	EOR	159.0	50.0	2026-11-09 11:04:05.181
37627	ArtisticGymnastics	No medal	Female	PAN	155.0	59.0	2026-11-09 11:04:05.181
37626	Boxing	Silver	Male	COL	165.0	49.0	2026-11-09 11:04:05.181
37625	Taekwondo	Gold	Male	AZE	200.0	93.0	2026-11-09 11:04:05.181
37624	Sailing	Gold	Male	NED	188.4	74.0	2026-11-09 11:04:05.181
37623	Skeleton	No medal	Female	AUT	174.0	63.0	2026-11-09 11:04:05.181
37622	MarathonSwimming	No medal	Male	GER	188.667	79.667	2026-11-09 11:04:05.181
37621	CanoeSprint	No medal	Female	INA	163.0	62.0	2026-11-09 11:04:05.181
37620	Wrestling	No medal	Female	PRK	157.4	54.8	2026-11-09 11:04:05.181
37619	Golf	No medal	Female	TPE	164.667	61.333	2026-11-09 11:04:05.181
37618	AlpineSkiing	No medal	Female	MKD	164.0	59.0	2026-11-09 11:04:05.181
37617	Weightlifting	Bronze	Male	LAT	180.667	132.333	2026-11-09 11:04:05.181
37616	Weightlifting	Silver	Male	LAT	181.0	145.0	2026-11-09 11:04:05.181
37615	Boxing	No medal	Female	COL	160.0	50.0	2026-11-09 11:04:05.181
37614	Shooting	Silver	Female	KOR	162.0	51.6	2026-11-09 11:04:05.181
37613	Boxing	Bronze	Female	COL	160.0	50.0	2026-11-09 11:04:05.181
37612	Taekwondo	Silver	Male	DOM	163.0	58.0	2026-11-09 11:04:05.181
37611	EquestrianDressage	No medal	Female	AUS	170.05	61.233	2026-11-09 11:04:05.181
37610	SkiJumping	Silver	Female	AUT	164.0	52.0	2026-11-09 11:04:05.181
37609	Fencing	No medal	Female	NZL	183.0	78.0	2026-11-09 11:04:05.181
37608	FreestyleSkiing	Silver	Male	FIN	169.333	69.333	2026-11-09 11:04:05.181
37607	Athletics	Silver	Male	GUA	178.0	60.0	2026-11-09 11:04:05.181
37606	Taekwondo	Bronze	Female	TPE	170.667	57.0	2026-11-09 11:04:05.181
37605	Skeleton	Bronze	Female	NED	166.0	65.0	2026-11-09 11:04:05.181
37604	Tennis	Bronze	Male	URS	180.0	73.0	2026-11-09 11:04:05.181

only showing top 30 rows

Таблиця в MySQL

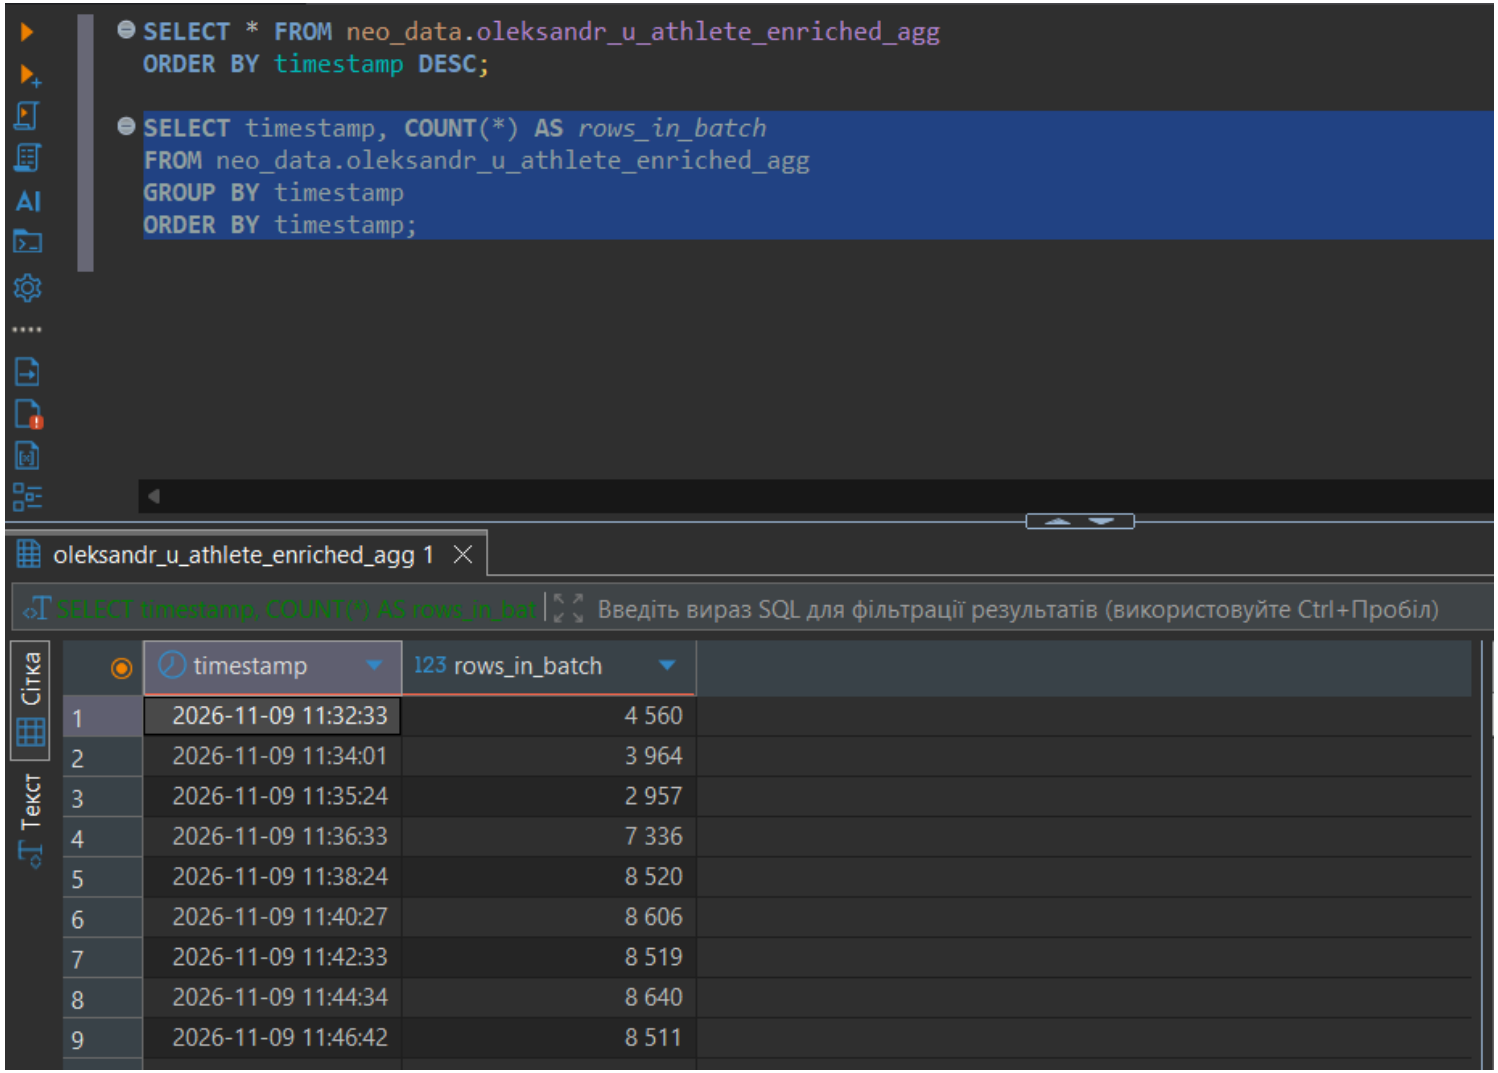
Етап 6.b. Те саме, що пішло в Kafka, лягає в `neo_data.oleksandr_u_athlete_enriched_agg`. Колонки як на прикладі з умови завдання: sport, medal, sex, country_noc, avg_height, avg_weight, timestamp.



	sport	medal	sex	country_noc	avg_height	avg_wei
1	Swimming	No medal	Female	FRA	172,775	
2	Softball	No medal	Female	TPE	163,972	
3	Athletics	No medal	Male	POL	180,916	
4	ArtisticGymnastics	No medal	Male	YUG	169,813	
5	Sailing	Silver	Male	SWE	181,077	
6	Sailing	No medal	Male	FIN	180,36	
7	Volleyball	No medal	Male	BRA	190,811	
8	Athletics	No medal	Male	POR	176,211	
9	Baseball	Silver	Male	CUB	182,297	
10	ArtisticGymnastics	No medal	Male	ITA	167,757	
11	IceHockey	Gold	Male	USA	180,058	
12	Swimming	No medal	Male	FRA	185,64	
13	Baseball	Gold	Male	CUB	182,317	
14	Sailing	No medal	Male	BAR	184,714	
15	Volleyball	No medal	Female	JPN	175,872	
16	Biathlon	No medal	Male	BLR	177,891	
17	Athletics	No medal	Female	RUS	172,421	
18	Biathlon	Gold	Male	BLR	180,571	
19	SpeedSkating	No medal	Male	RUS	183,215	
20	Volleyball	No medal	Male	KOR	188,27	
21	WaterPolo	No medal	Male	JPN	176,279	
22	Sailing	Bronze	Male	USA	183,722	
23	WaterPolo	No medal	Male	AUS	188,165	
24	Handball	Bronze	Male	ESP	192,698	
25	Sailing	No medal	Male	CAN	180,011	
26	Handball	No medal	Male	HUN	189,471	
27	CrossCountrySkiing	No medal	Male	JPN	168,281	
28	Swimming	No medal	Male	GBR	185,19	
29	Sailing	No medal	Male	BEL	180,469	

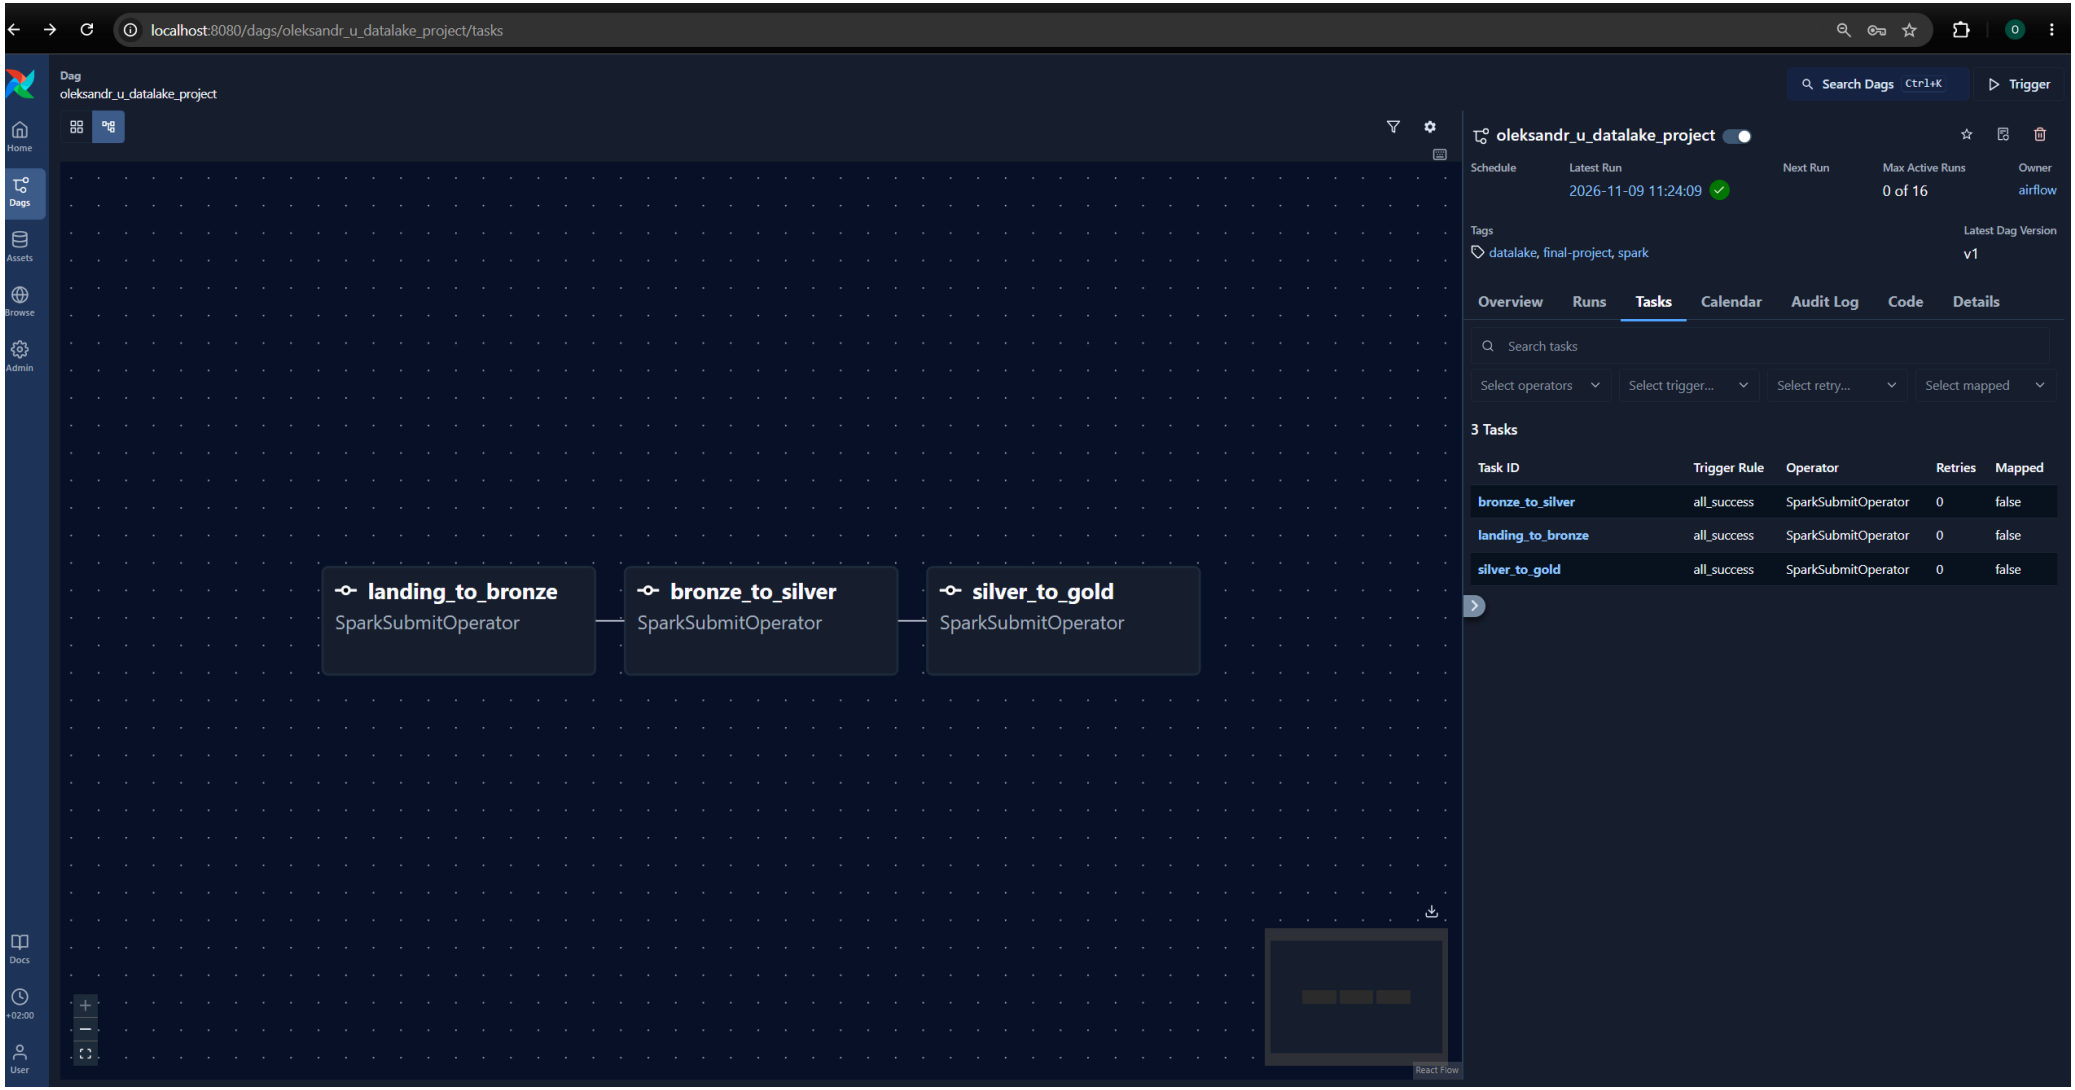
Запис мікробатчами

Групування за `timestamp` показує 9 мікробатчів по 100 тис. повідомлень. Режим `update`: кожен батч перевидає групи, в які додалися нові атлети, тому рядків у батчі з часом більшає.



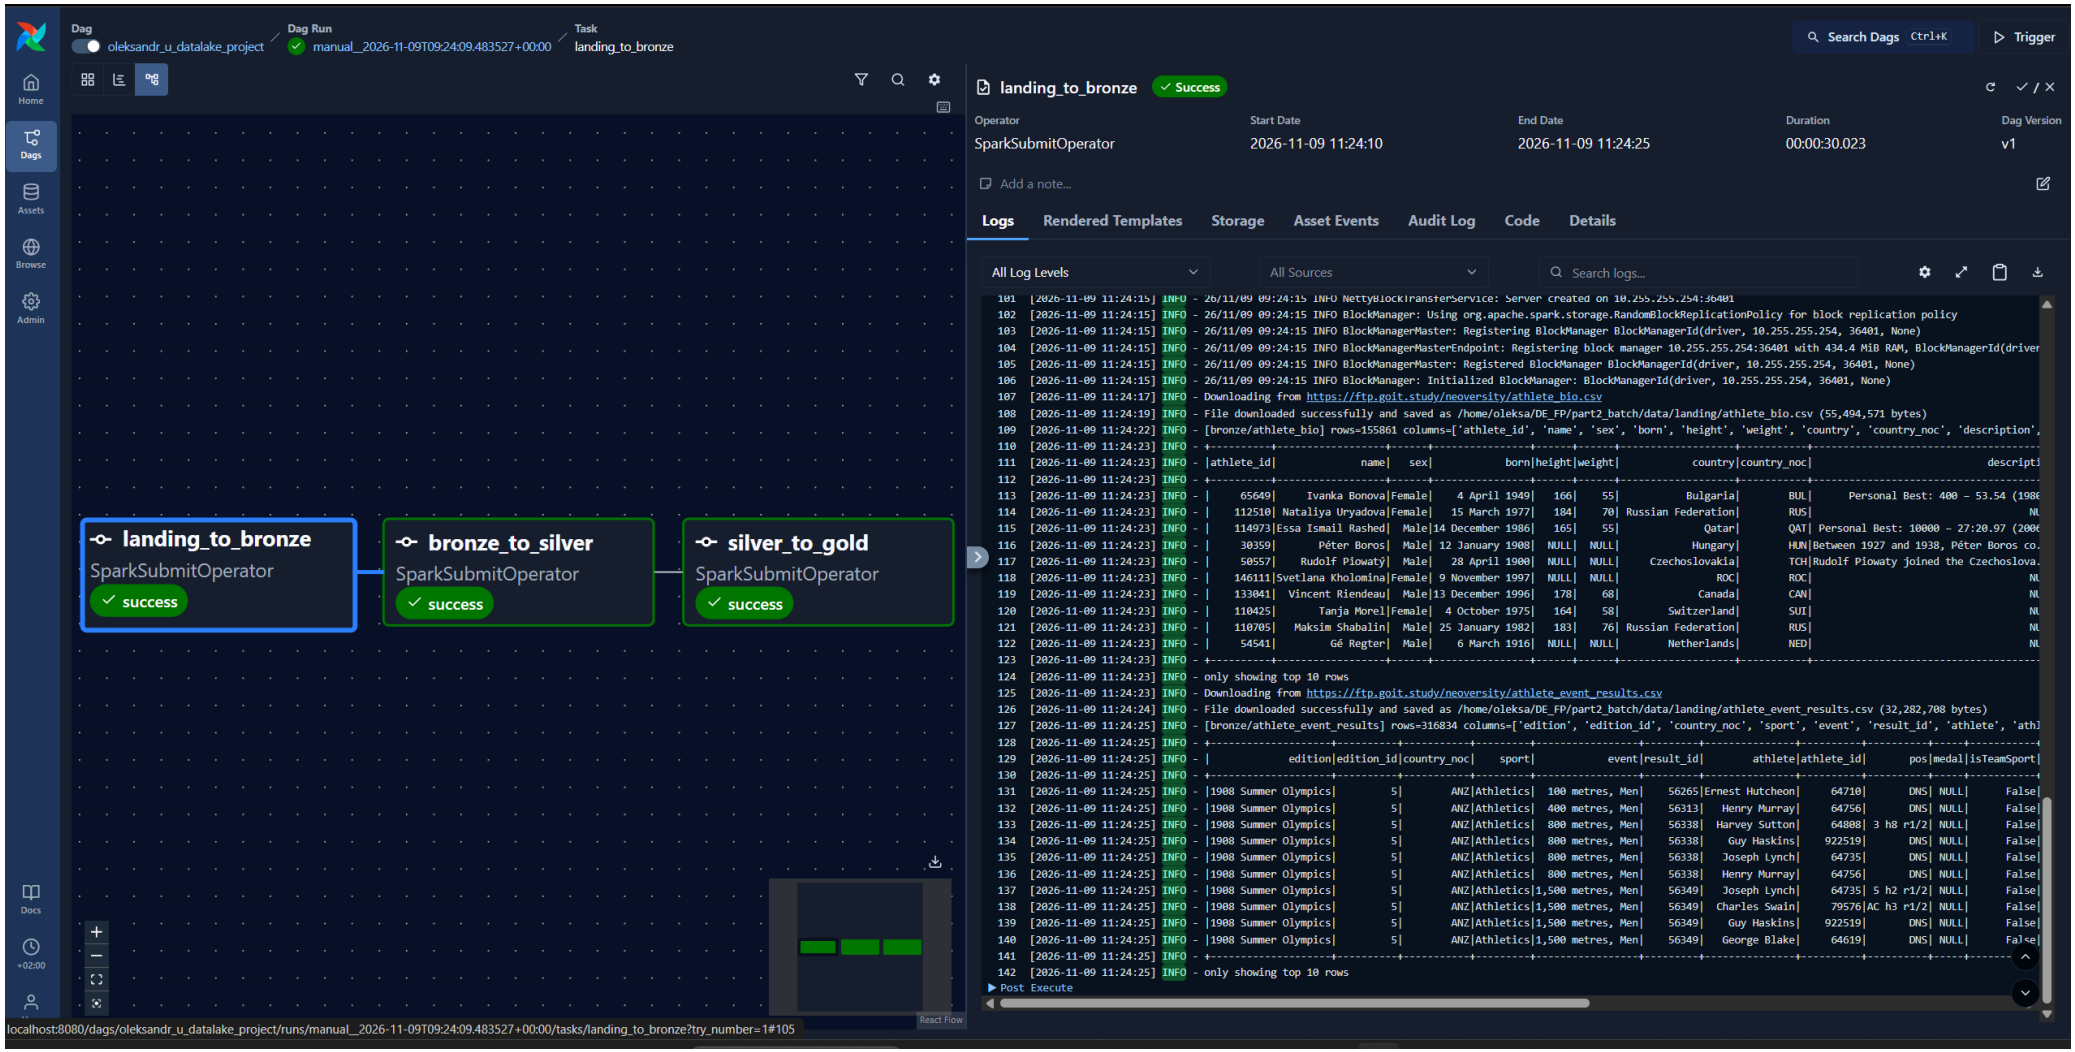
Частина 2. Batch Data Lake: landing → bronze → silver → gold

Три Spark-джоби в `part2_batch/` запускає Airflow DAG `oleksandr_u_datalake_project` (`project_solution.py`, SparkSubmitOperator) — строго по черзі. На наступних сторінках той самий граф після запуску: усі три задачі success.



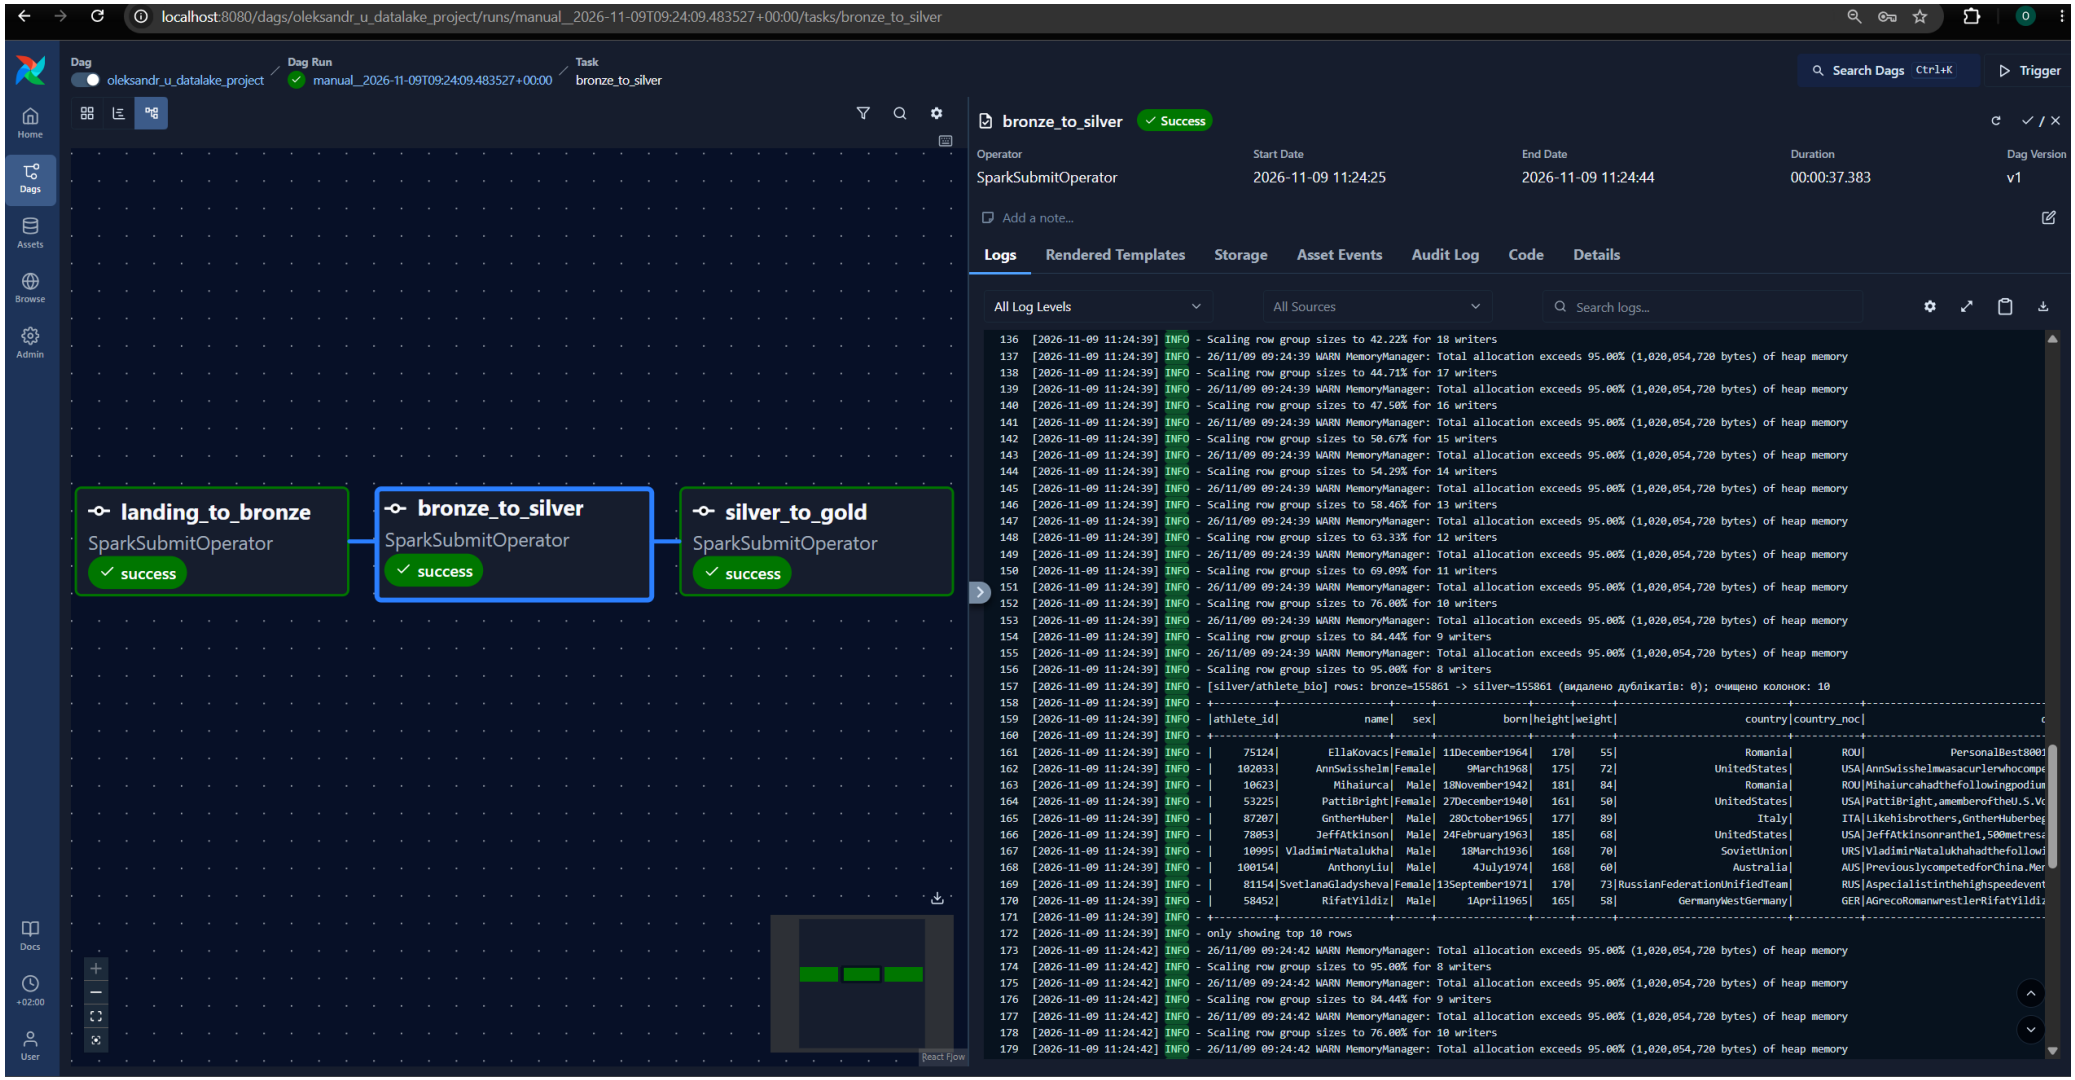
landing_to_bronze

CSV тягнуться з FTP як є, Spark читає їх і кладе в parquet `bronze/athlete_bio` (155 861 рядок) і `bronze/athlete_event_results` (316 834).



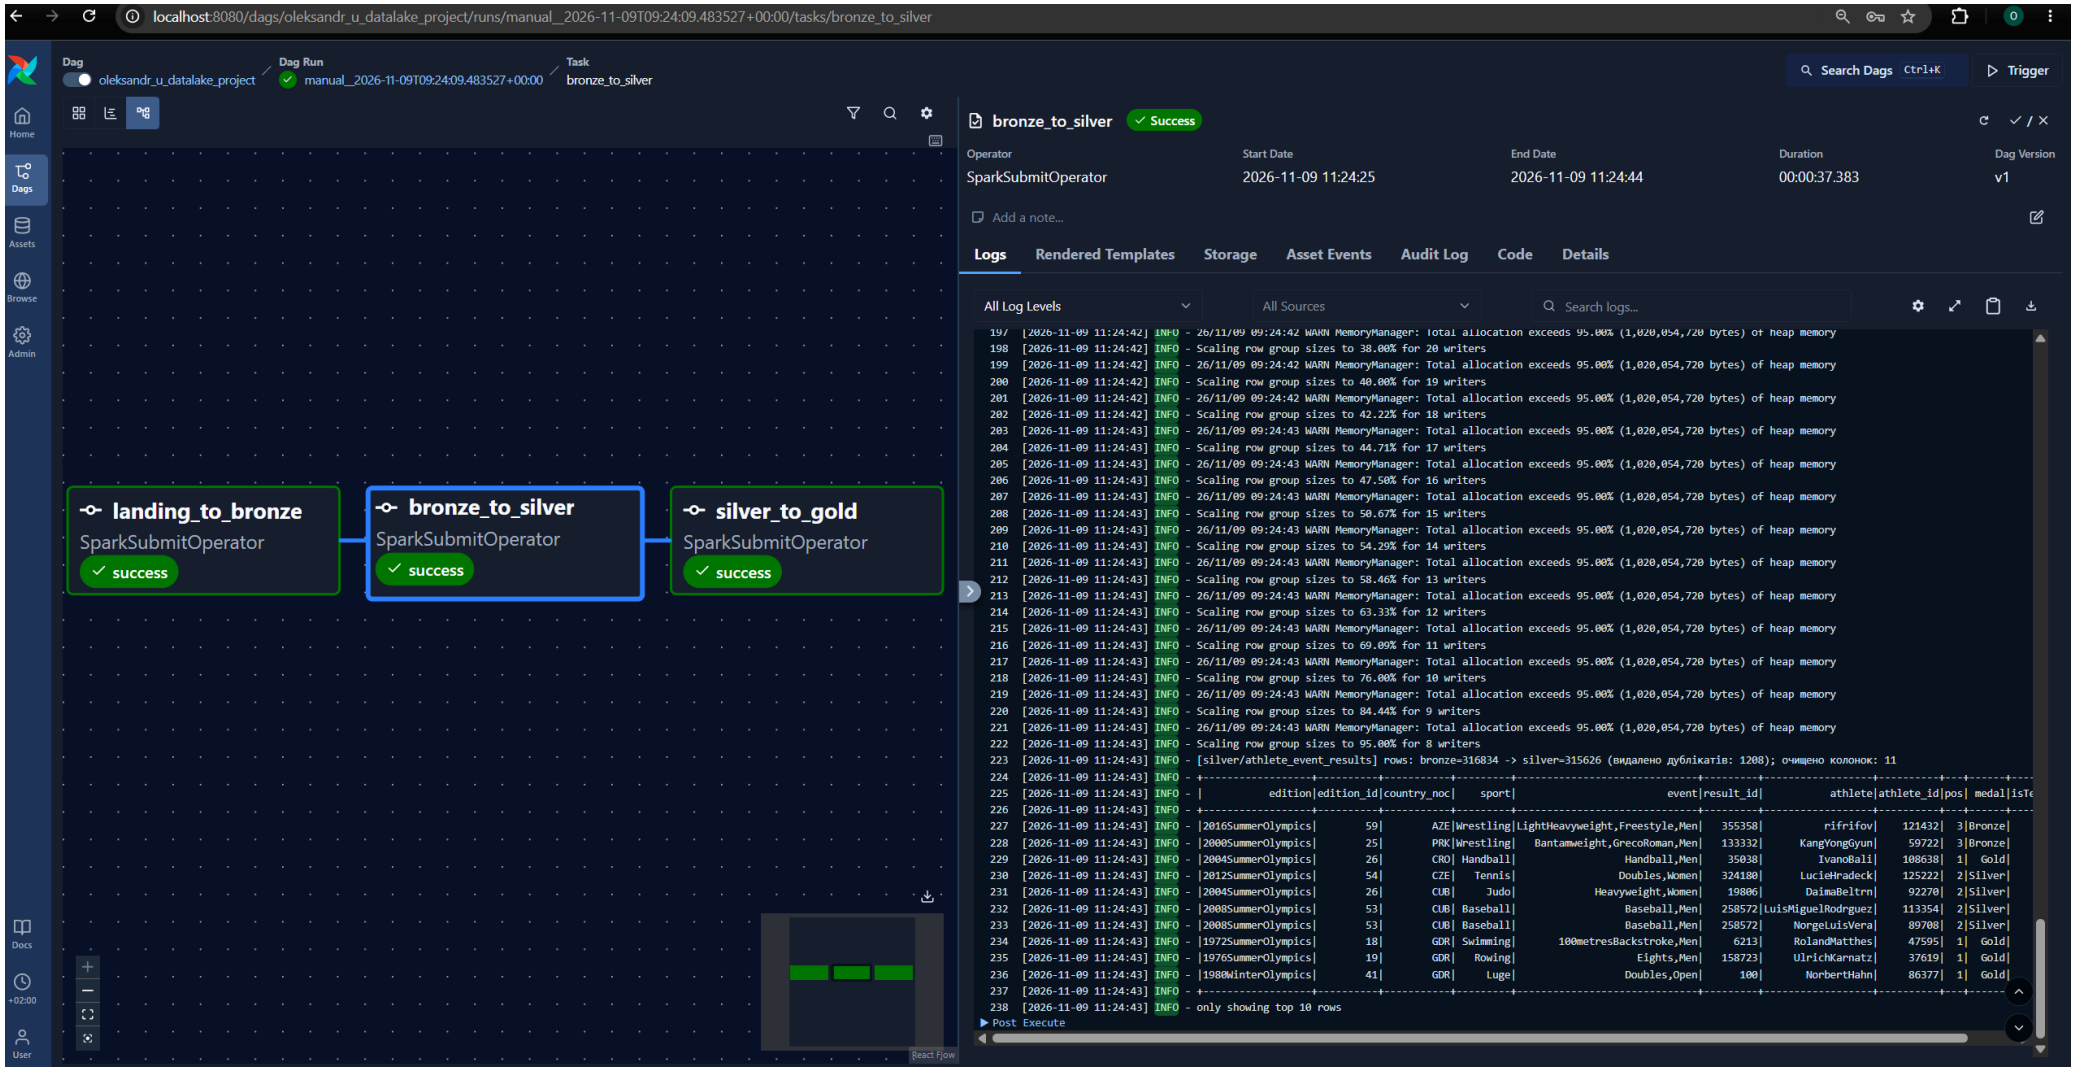
bronze_to_silver: athlete_bio

Усі текстові колонки проходять через `clean_text` (UDF з порад до виконання завдання), потім дедублікація. У біо дублікатів нема: 155 861 → 155 861.



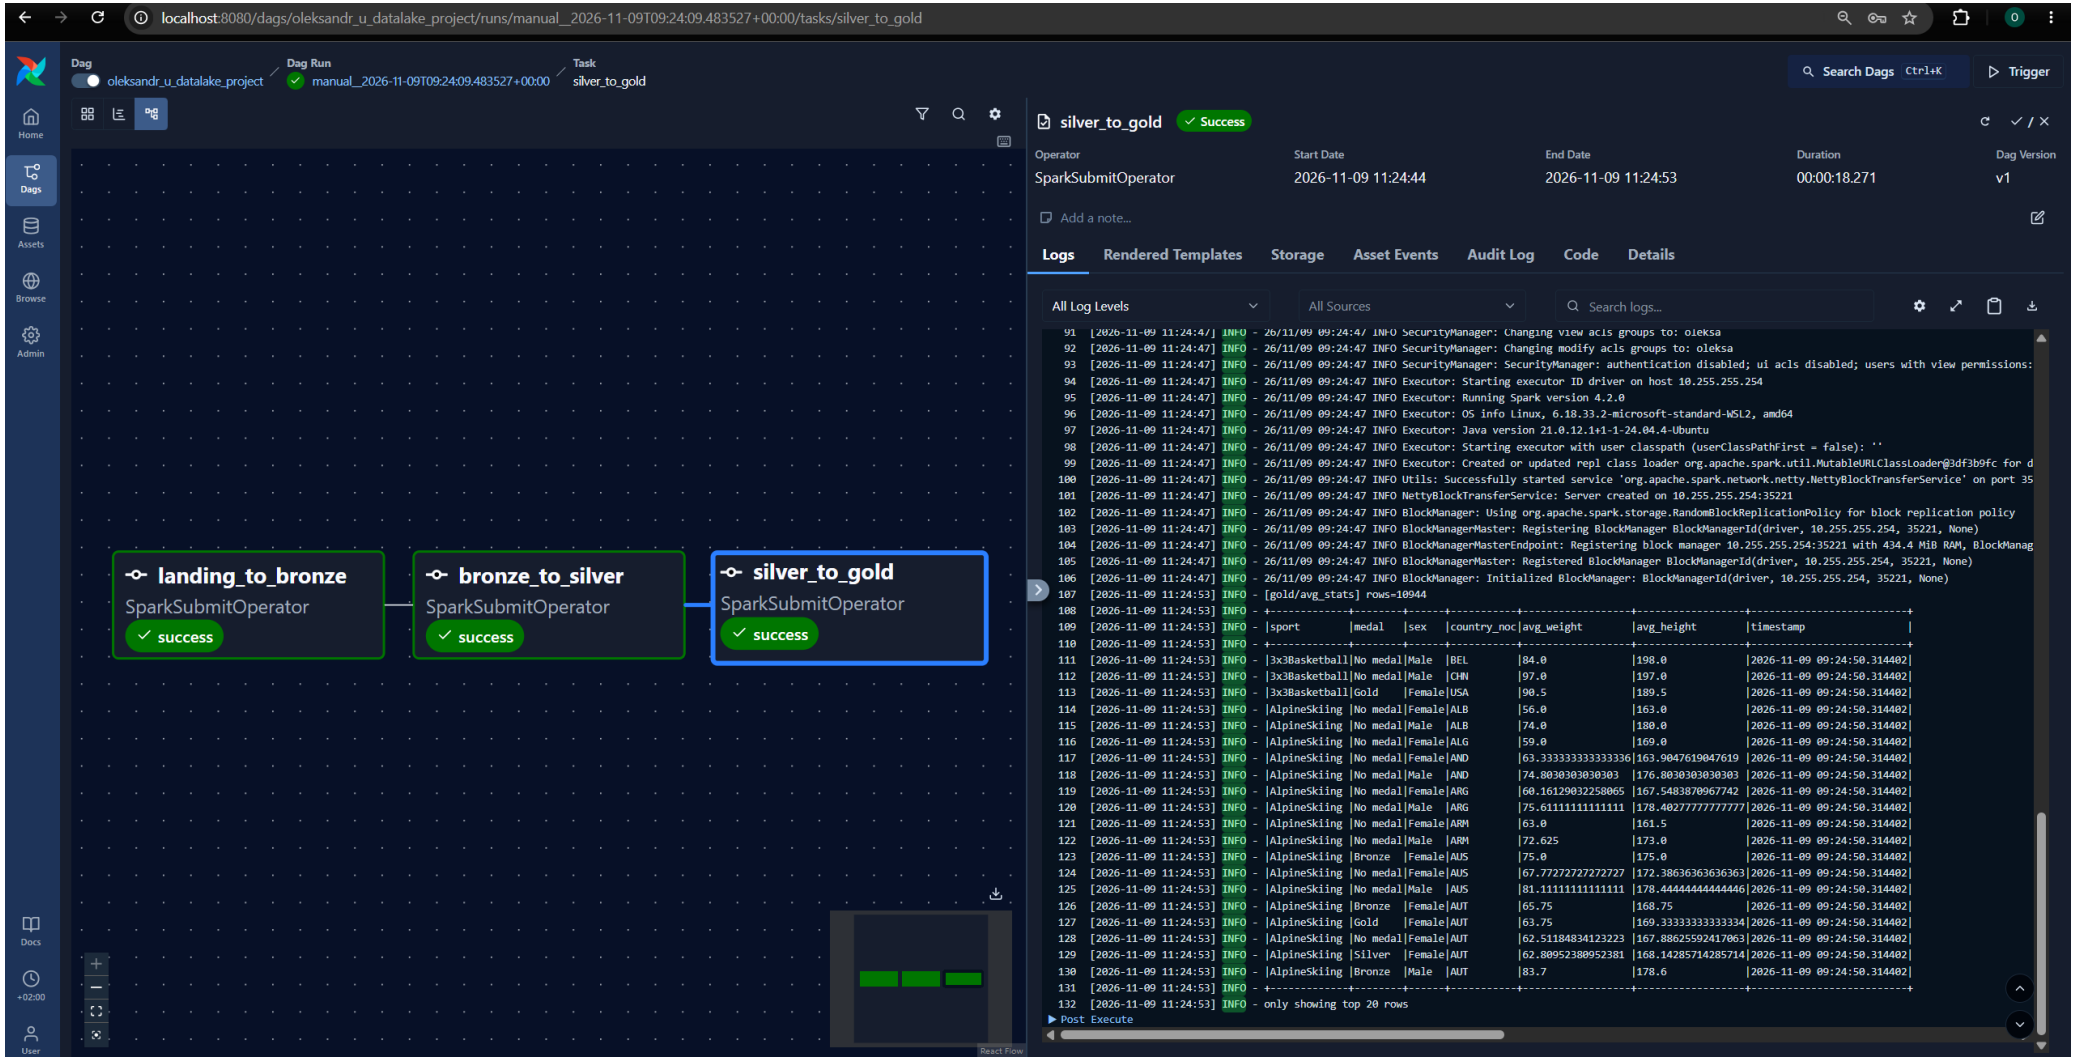
bronze_to_silver: athlete_event_results

У результатах прибрано 1 208 дублікатів: 316 834 → 315 626. Видно ефект чистки: `2016SummerOlympics`, `LightHeavyweight,Freestyle,Men`.



silver_to_gold

Join двох silver-таблиць за `athlete_id`, weight і height приведено до чисел, середні за sport / medal / sex / country_noc + колонка `timestamp`. Результат — `gold/avg_stats`, 10 944 рядки.



Час у логах Spark — UTC (09:24), в інтерфейсі Airflow — київський (11:24).